
Eduardo Gomes Martins e Lucas de Lima Bergami

Integração de Informações Textuais e Estruturais para Predição de Colaboração no GitHub

1 Introdução

A mineração de texto consiste no processo de extração de informação útil a partir de dados textuais não estruturados por meio de etapas como coleta, pré-processamento, representação vetorial e análise. Inserida dentro do contexto mais amplo de descoberta de conhecimento em bases de dados (KDD), essa abordagem permite transformar conteúdo textual produzido em plataformas digitais em conhecimento passível de análise computacional.

Neste trabalho, foi utilizada a plataforma GitHub como objeto de estudo. Além de atuar como ambiente de hospedagem e colaboração de software, o GitHub pode ser interpretado como uma rede social de desenvolvedores, na qual usuários produzem conteúdo textual por meio de biografias, descrições de projetos, arquivos README e interações relacionadas aos repositórios.

A coleta dos dados foi realizada utilizando a API pública REST do GitHub, mantendo como base o conjunto de usuários e repositórios obtidos no trabalho anterior. A partir desses dados, foram extraídas informações textuais associadas aos usuários principalmente biografias e README de perfil e aos repositórios incluindo descrições e conteúdo textual dos arquivos README.

Após a etapa de extração, os textos passaram por técnicas clássicas de pré-processamento, incluindo limpeza, remoção de termos irrelevantes e normalização linguística. Em seguida, os documentos foram convertidos para representação vetorial utilizando TF-IDF (*Term Frequency–Inverse Document Frequency*), permitindo transformar o conteúdo textual em atributos numéricos.

Com os vetores gerados, foi calculada a similaridade do cosseno entre usuários e repositórios, produzindo uma medida de proximidade textual baseada nos interesses, tecnologias e temas presentes nos documentos analisados. Essa informação foi incorporada ao dataset relacional previamente construído como uma nova feature para um problema supervisionado de classificação binária.

O objetivo da tarefa consiste em prever se um determinado usuário possui relação de contribuição com um repositório específico. Para isso, foram avaliados modelos de classificação utilizando tanto atributos estruturais quanto a nova informação derivada da mineração textual.

Nas próximas seções são descritas as etapas de coleta, processamento dos textos, construção das representações vetoriais, geração das métricas de similaridade e avaliação dos modelos empregados.

2 Coleta e Processamento de Dados Textuais

Além dos atributos estruturais originalmente coletados do GitHub, este trabalho incorporou informações textuais produzidas pelos usuários e descrições dos projetos com o objetivo de aplicar técnicas de mineração de texto sobre a rede social.

A coleta foi realizada utilizando a API REST do GitHub e foi dividida em duas frentes complementares: coleta textual dos usuários e coleta textual dos repositórios.

Para os usuários, foram extraídos dois tipos principais de conteúdo textual:

- biografia pública (*bio*);
- conteúdo do repositório especial de perfil (*Profile README*), quando disponível.

Esses textos foram concatenados para formar uma representação textual única do usuário. Para os repositórios, foram coletados:

- descrição pública do projeto;
- conteúdo do arquivo README principal.

Da mesma forma, esses elementos foram combinados em um único documento textual representando cada repositório.

Após a coleta, os textos passaram por uma etapa de pré-processamento com o objetivo de reduzir ruídos e padronizar o conteúdo analisado. Foram aplicadas as seguintes transformações:

- conversão para letras minúsculas;
- remoção de URLs;
- remoção de marcações Markdown e HTML;
- remoção de números;
- remoção de caracteres especiais;
- remoção de *stopwords*;
- lematização dos termos.

Após a limpeza, os documentos textuais foram convertidos para representação numérica utilizando a técnica TF-IDF (*Term Frequency–Inverse Document Frequency*).

A vetorização foi realizada separadamente para usuários e repositórios, produzindo matrizes esparsas que representam a importância relativa de cada termo dentro de cada conjunto textual.

Essa representação permitiu transformar textos livres em vetores comparáveis matematicamente, preservando termos mais característicos e reduzindo o peso de palavras muito frequentes.

3 Construção da Similaridade Textual e Integração ao Dataset

Com os textos vetorizados, foi adicionada uma etapa de correlação semântica entre usuários e repositórios.

Inicialmente, para cada instância da tabela relacional, foram recuperados:

- o vetor TF-IDF associado ao usuário;
- o vetor TF-IDF associado ao repositório.

Como usuário e repositório foram vetorizados em um espaço textual compartilhado, tornou-se possível medir o grau de proximidade entre ambos utilizando Similaridade do Cosseno (*Cosine Similarity*).

A Similaridade do Cosseno mede o ângulo entre dois vetores e retorna valores no intervalo:

$$[-1, 1]$$

onde valores próximos de 1 indicam alta proximidade textual e valores próximos de 0 indicam baixa relação semântica.

Formalmente:

$$\text{CosineSimilarity}(A, B) = \frac{A \cdot B}{\|A\| \cdot \|B\|}$$

Para cada par usuário–repositório presente na tabela correlacionada foi calculado um valor de similaridade textual.

Esse valor foi então incorporado como uma nova feature denominada:

`text_cosine_similarity`

A hipótese investigada foi que usuários cuja descrição profissional e interesses técnicos apresentam maior proximidade textual com a descrição e documentação do repositório possuem maior probabilidade de contribuir para aquele projeto.

Após a inclusão dessa nova feature, os modelos de classificação foram treinados novamente para avaliar se a informação textual acrescentaria capacidade preditiva em relação ao conjunto original de atributos estruturais e relacionais.

4 Vetorização TF-IDF

A vetorização TF-IDF (*Term Frequency - Inverse Document Frequency*) é uma técnica estatística utilizada no processamento de linguagem natural para avaliar a importância de uma palavra em um documento que faz parte de uma coleção (corpus).

O cálculo é composto por duas partes principais:

1. **TF (Frequência do Termo):** Mede a frequência com que uma palavra t aparece em um documento específico d .

$$TF(t, d) = \frac{\text{Número de vezes que } t \text{ aparece em } d}{\text{Total de termos em } d} \quad (4.1)$$

2. **IDF (Frequência Inversa dos Documentos):** Mede a importância geral do termo no corpus. Palavras muito frequentes em todos os documentos (como artigos e preposições) ganham um peso menor.

$$IDF(t, D) = \log \left(\frac{\text{Número total de documentos } |D|}{1 + \text{Número de documentos que contêm o termo } t} \right) \quad (4.2)$$

O valor final do TF-IDF é obtido através do produto de ambas as métricas:

$$TF-IDF(t, d, D) = TF(t, d) \times IDF(t, D) \quad (4.3)$$

Como resultado, o algoritmo transforma o texto em uma matriz numérica, onde termos que são frequentes em um documento específico, mas raros no restante do corpus, recebem os maiores pesos.

5 Resultados

A avaliação dos modelos foi realizada sobre o conjunto de teste utilizando métricas tradicionais de classificação binária: Accuracy, Precision, Recall, F1-Score e ROC-AUC.

Além da análise isolada do desempenho dos modelos, foi realizada uma comparação direta com os resultados obtidos no trabalho anterior, cujo conjunto de atributos era composto apenas por informações estruturais e relacionais do GitHub. Neste trabalho, foi incorporada uma nova dimensão baseada em mineração de texto, utilizando informações extraídas das biografias dos usuários, READMEs de perfil, descrições dos repositórios e arquivos README dos projetos.

Os textos coletados foram pré-processados e convertidos em representações vetoriais utilizando TF-IDF. Em seguida, foi calculada a Similaridade do Cosseno entre cada usuário e repositório, gerando a feature `text_cosine_similarity`, posteriormente integrada ao dataset relacional.

Foram novamente treinados os modelos *Random Forest* e *Logistic Regression*, permitindo avaliar o impacto da inclusão da informação textual no desempenho preditivo.

5.1 Comparação dos Modelos

A Figura 1 apresenta a comparação dos modelos utilizando a métrica F1-Score.




Figura 1: Comparação de F1-Score entre os modelos após inclusão da similaridade textual.

A Figura 2 apresenta a comparação considerando ROC-AUC.




Figura 2: Comparação da métrica ROC-AUC entre os modelos.

A Tabela 1 resume os resultados obtidos.

Tabela 1: Comparação dos modelos com inclusão de atributos textuais

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC
Random Forest	0.5769	0.6000	0.4615	0.5217	0.6450
Logistic Regression	0.6538	0.6429	0.6923	0.6667	0.6036

5.2 Matrizes de Confusão




Figura 3: Matriz de confusão — Random Forest




Figura 4: Matriz de confusão — Logistic Regression

As matrizes permitem observar diferenças importantes entre os modelos. O Random Forest apresentou comportamento mais conservador, reduzindo falsos positivos, porém aumentando falsos negativos. Já a Regressão Logística apresentou distribuição mais equilibrada entre as classes.

5.3 Importância das Features




Figura 5: Importância das features no Random Forest

A análise da importância das features permite investigar o impacto da nova dimensão textual adicionada ao dataset.

5.4 Comparação com o Trabalho Anterior

A Tabela 2 apresenta a comparação entre os resultados anteriores e os obtidos após inclusão da Similaridade do Cosseno baseada em TF-IDF.

Tabela 2: Comparação entre versão original e versão com mineração de texto

Modelo	Accuracy	Recall	F1	ROC-AUC
RF (Anterior)	0.5769	0.5385	0.5600	0.6834
RF (Texto)	0.5769	0.4615	0.5217	0.6450
LR (Anterior)	0.5769	0.6923	0.6207	0.6391
LR (Texto)	0.6538	0.6923	0.6667	0.6036

Observa-se que os efeitos da inclusão das informações textuais foram diferentes para cada modelo.

No caso do Random Forest, não houve ganho em acurácia e ocorreu redução em Recall, F1-Score e ROC-AUC. Isso sugere que a inclusão da similaridade textual introduziu informação adicional, porém possivelmente mais ruidosa para modelos baseados em árvores, dificultando a separação entre contribuidores e não contribuidores.

Por outro lado, a Regressão Logística apresentou melhora consistente. A acurácia aumentou de 57,69% para 65,38%, enquanto o F1-Score passou de 0,6207 para 0,6667. O Recall permaneceu elevado (0,6923), indicando manutenção da capacidade de identificar contribuidores reais.

Esse comportamento sugere que a Similaridade do Cosseno baseada em TF-IDF adicionou informação complementar às features estruturais existentes. Como a Regressão Logística é um modelo linear, ela tende a aproveitar melhor sinais contínuos derivados de proximidade semântica entre usuários e repositórios.

Embora o ROC-AUC tenha apresentado pequena redução na Regressão Logística, o ganho em Accuracy e F1 indica melhora prática no equilíbrio geral das classificações.

Os resultados indicam que informações textuais extraídas automaticamente dos perfis e documentações do GitHub possuem potencial para enriquecer tarefas de recomendação e previsão de colaboração entre desenvolvedores e projetos.

6 Conclusão

Este trabalho investigou o impacto da inclusão de atributos derivados de mineração de texto no problema de predição de contribuição de usuários em repositórios do GitHub. A hipótese central baseava-se na premissa de que a proximidade semântica entre desenvolvedores e projetos, calculada via similaridade do cosseno sobre vetores TF-IDF, enriqueceria o conjunto de *features* estruturais e aumentaria a capacidade preditiva dos classificadores.

Os resultados obtidos revelaram que os efeitos dessa integração foram distintos para cada arquitetura texturizada. No caso do *Random Forest*, a introdução da similaridade textual não gerou ganhos em acurácia e provocou uma redução nas métricas de *Recall*, *F1-Score* e ROC-AUC. Esse comportamento indica que a nova variável pode ter introduzido ruído para o modelo baseado em árvores de decisão, elevando a complexidade do espaço de busca e dificultando a segregação das classes.

Por outro lado, a *Regressão Logística* demonstrou maior sensibilidade e eficiência ao lidar com o novo atributo, apresentando um comportamento consistente e superior em métricas decisivas para cenários desbalanceados. O modelo linear alcançou o maior *F1-Score* (0,6207) e uma expressiva taxa de *Recall* (0,6923). Essa dinâmica confirma que a similaridade do cosseno atua como uma informação complementar valiosa para modelos lineares, que conseguem extrair melhor proveito de sinais contínuos de proximidade semântica. Embora ambos os modelos tenham empatado na acurácia geral (57,69%), o ganho prático no equilíbrio das classificações valida o uso da Regressão Logística para esta abordagem.

As limitações observadas no desempenho global, como os valores moderados de acurácia, estão diretamente associadas à complexidade imposta pela estratégia de *negativos difíceis* no

dataset e ao volume restrito de dados decorrente dos limites de requisição da API do GitHub.

Ainda assim, o estudo confirma o potencial de informações textuais extraídas automaticamente de perfis e documentações para enriquecer sistemas de recomendação e previsão de colaboração no ecossistema de desenvolvimento. Para trabalhos futuros, recomenda-se mitigar a esparsidade do TF-IDF através do uso de *embeddings* densos gerados por modelos de linguagem baseados em *Transformers* (como o *Sentence-BERT*), além da expansão da base de dados por meio de coletas distribuídas no tempo.